

# AG2 - Actividad Guiada 2

Nombre: Johnny Andres Illescas Fernandez

Link:

<https://colab.research.google.com/drive/1FpirdSakwX4LYAat3PTOvICdzzUoaVq8?usp=sharing>

Github:

[https://github.com/AndresGin/VIU\\_Algoritmos\\_de\\_optimizacion/tree/main/AG2](https://github.com/AndresGin/VIU_Algoritmos_de_optimizacion/tree/main/AG2)


In [ ]: `import math`

## Programación Dinámica. Viaje por el río

- **Definición:** Es posible dividir el problema en subproblemas más pequeños, guardando las soluciones para ser utilizadas más adelante.
- **Características** que permiten identificar problemas aplicables:
  - Es posible almacenar soluciones de los subproblemas para ser utilizados más adelante
  - Debe verificar el principio de optimalidad de Bellman: "en una secuencia optima de decisiones, toda sub-secuencia también es óptima" (\*)
  - La necesidad de guardar la información acerca de las soluciones parciales unido a la recursividad provoca la necesidad de preocuparnos por la complejidad espacial (cuantos recursos de espacio usaremos)

## Problema

En un río hay  $n$  embarcaderos y debemos desplazarnos río abajo desde un embarcadero a otro. Cada embarcadero tiene precios diferentes para ir de un embarcadero a otro situado más abajo. Para ir del embarcadero  $i$  al  $j$ , puede ocurrir que sea más barato hacer un trasbordo por un embarcadero intermedio  $k$ . El problema consiste en determinar la combinación más barata.



\*Consideramos una tabla TARIFAS(i,j) para almacenar todos los precios que nos ofrecen los embarcaderos.

\*Si no es posible ir desde i a j daremos un valor alto para garantizar que ese trayecto no se va a elegir en la ruta óptima(modelado habitual para restricciones)

```
In [2]: #Viaje por el rio – Programación dinámica
#####

TARIFAS = [
[0,5,4,3,float("inf"),999,999], #desde nodo 0
[999,0,999,2,3,999,11], #desde nodo 1
[999,999, 0,1,999,4,10], #desde nodo 2
[999,999,999, 0,5,6,9],
[999,999, 999,999,0,999,4],
[999,999, 999,999,999,0,3],
[999,999,999,999,999,999,0]
]

#999 se puede sustituir por float("inf") del modulo math
TARIFAS
```

```
Out[2]: [[0, 5, 4, 3, inf, 999, 999],
[999, 0, 999, 2, 3, 999, 11],
[999, 999, 0, 1, 999, 4, 10],
[999, 999, 999, 0, 5, 6, 9],
[999, 999, 999, 999, 0, 999, 4],
[999, 999, 999, 999, 999, 0, 3],
[999, 999, 999, 999, 999, 999, 0]]
```

```
In [3]: #Calculo de la matriz de PRECIOS y RUTAS
# PRECIOS – contiene la matriz del mejor precio para ir de un nodo a otro
# RUTAS – contiene los nodos intermedios para ir de un nodo a otro
#####
def Precios(TARIFAS):
#####
#Total de Nodos
N = len(TARIFAS[0])

#Inicialización de la tabla de precios
PRECIOS = [ [9999]*N for i in range(N)] #n x n
RUTA = [ [0]*N for i in range(N)]

#Se recorren todos los nodos con dos bucles(origen – destino)
# para ir construyendo la matriz de PRECIOS
for i in range(N-1):
    for j in range(i+1, N):
        MIN = TARIFAS[i][j]
        RUTA[i][j] = i

        for k in range(i, j):
            if PRECIOS[i][k] + TARIFAS[k][j] < MIN:
                MIN = min(MIN, PRECIOS[i][k] + TARIFAS[k][j] )
                RUTA[i][j] = k
                PRECIOS[i][j] = MIN

    return PRECIOS,RUTA
```

```
In [4]: PRECIOS, RUTA = Precios(TARIFAS)
        #print(PRECIOS[0][6])

        print("PRECIOS")
        for i in range(len(TARIFAS)):
            print(PRECIOS[i])

        print("\nRUTA")
        for i in range(len(TARIFAS)):
            print(RUTA[i])
```

```
PRECIOS
[9999, 5, 4, 3, 8, 8, 11]
[9999, 9999, 999, 2, 3, 8, 7]
[9999, 9999, 9999, 1, 6, 4, 7]
[9999, 9999, 9999, 9999, 5, 6, 9]
[9999, 9999, 9999, 9999, 9999, 999, 4]
[9999, 9999, 9999, 9999, 9999, 9999, 3]
[9999, 9999, 9999, 9999, 9999, 9999, 9999]
```

```
RUTA
['', 0, 0, 0, 1, 2, 5]
['', '', 1, 1, 1, 3, 4]
['', '', '', 2, 3, 2, 5]
['', '', '', '', 3, 3, 3]
['', '', '', '', '', 4, 4]
['', '', '', '', '', '', 5]
['', '', '', '', '', '', '']
```

```
In [5]: #Calculo de la ruta usando la matriz RUTA
        def calcular_ruta(RUTA, desde, hasta):
            if desde == RUTA[desde][hasta]:
                #if desde == hasta:
                    #print("Ir a :" + str(desde))
                    return desde
            else:
                return str(calcular_ruta(RUTA, desde, RUTA[desde][hasta])) + ',' + s

        print("\nLa ruta es:")
        calcular_ruta(RUTA, 0,6)
```

La ruta es:

```
Out [5]: '0,2,5'
```

## Problema de Asignacion de tarea

```
In [6]: #Asignacion de tareas - Ramificación y Poda
        #####
        #   T A R E A
        #   A
        #   G
        #   E
        #   N
        #   T
        #   E

        COSTES= [[11,12,18,40],
```

```
[14,15,13,22],
[11,17,19,23],
[17,14,20,28]]
```

In [7]: *#Calculo del valor de una solucion parcial*

```
def valor(S,COSTES):
    VALOR = 0
    for i in range(len(S)):
        VALOR += COSTES[S[i]][i]
    return VALOR
```

```
valor((3,2, ),COSTES)
```

Out[7]: 34

In [8]: *#Coste inferior para soluciones parciales*  
*# (1,3,) Se asigna la tarea 1 al agente 0 y la tarea 3 al agente 1*

```
def CI(S,COSTES):
    VALOR = 0
    #Valores establecidos
    for i in range(len(S)):
        VALOR += COSTES[i][S[i]]

    #Estimacion
    for i in range( len(S), len(COSTES) ):
        VALOR += min( [ COSTES[j][i] for j in range(len(S), len(COSTES)) ] )
    return VALOR
```

```
def CS(S,COSTES):
    VALOR = 0
    #Valores establecidos
    for i in range(len(S)):
        VALOR += COSTES[i][S[i]]

    #Estimacion
    for i in range( len(S), len(COSTES) ):
        VALOR += max( [ COSTES[j][i] for j in range(len(S), len(COSTES)) ] )
    return VALOR
```

```
CI((0,1),COSTES)
```

Out[8]: 68

In [9]: *#Genera tantos hijos como como posibilidades haya para la siguiente eleme*  
*#(0,) -> (0,1), (0,2), (0,3)*

```
def crear_hijos(NODO, N):
    HIJOS = []
    for i in range(N ):
        if i not in NODO:
            HIJOS.append({'s':NODO +(i, ) })
    return HIJOS
```

In [10]: crear\_hijos((0, ) , 4)

Out[10]: [{'s': (0, 1)}, {'s': (0, 2)}, {'s': (0, 3)}]

```

In [11]: def ramificacion_y_poda(COSTES):
#Construccion iterativa de soluciones(arbol). En cada etapa asignamos un
#Nodos del grafo { s:(1,2),CI:3,CS:5 }
#print(COSTES)
DIMENSION = len(COSTES)
MEJOR_SOLUCION=tuple( i for i in range(len(COSTES)) )
CotaSup = valor(MEJOR_SOLUCION,COSTES)
#print("Cota Superior:", CotaSup)

NODOS=[]
NODOS.append({'s':(), 'ci':CI((),COSTES) } )

iteracion = 0

while( len(NODOS) > 0):
    iteracion +=1

    nodo_prometedor = [ min(NODOS, key=lambda x:x['ci']) ][0]['s']
    #print("Nodo prometedor:", nodo_prometedor)

    #Ramificacion
    #Se generan los hijos
    HIJOS =[ {'s':x['s'], 'ci':CI(x['s'], COSTES) } for x in crear_hijo

    #Revisamos la cota superior y nos quedamos con la mejor solucion si l
    NODO_FINAL = [x for x in HIJOS if len(x['s']) == DIMENSION ]
    if len(NODO_FINAL) >0:
        #print("\n*****Soluciones:", [x for x in HIJOS if len(x['s']) =
        if NODO_FINAL[0]['ci'] < CotaSup:
            CotaSup = NODO_FINAL[0]['ci']
            MEJOR_SOLUCION = NODO_FINAL

    #Poda
    HIJOS = [x for x in HIJOS if x['ci'] < CotaSup ]

    #Añadimos los hijos
    NODOS.extend(HIJOS)

    #Eliminamos el nodo ramificado
    NODOS = [ x for x in NODOS if x['s'] != nodo_prometedor ]

    print("La solucion final es:" ,MEJOR_SOLUCION , " en " , iteracion , "

```

```

In [12]: ramificacion_y_poda(COSTES)

```

La solucion final es: [{'s': (1, 2, 0, 3), 'ci': 64}] en 10 iteraciones para dimension: 4

## Implementacion de tarea 1

```

In [13]: #Imports
import numpy as np
import itertools
import time
import pandas as pd
import matplotlib.pyplot as plt

from google.colab.data_table import DataTable

In [14]: # Función para generar matrices de costos aleatorias
def generar_matriz_costos(dimension, rango=(10, 50)):
    return np.random.randint(rango[0], rango[1], size=(dimension, dimensi

In [15]: # Algoritmo de Fuerza Bruta
def fuerza_bruta(COSTES):
    start_time = time.time() # Medir tiempo de ejecución

    N = len(COSTES) # Número de tareas/agentes
    mejor_valor = float('inf') # Inicializamos con infinito
    mejor_solucion = ()

    for s in itertools.permutations(range(N)): # Todas las asignaciones
        valor_tmp = valor(s, COSTES)
        if valor_tmp < mejor_valor:
            mejor_valor = valor_tmp
            mejor_solucion = s

    elapsed_time = time.time() - start_time # Tiempo transcurrido

    print(f"\nFuerza Bruta: Mejor solución: {mejor_solucion} con costo: {
    print(f"Tiempo de ejecución: {elapsed_time:.4f} segundos")

    return mejor_valor, elapsed_time

In [16]: resultados = []

for N in range(3, 12): # Desde 3x3 hasta 15x15
    print(f"\n=== Evaluando N={N} ===")
    COSTES = generar_matriz_costos(N)

    # Evaluar Fuerza Bruta
    fb_costo, fb_tiempo = fuerza_bruta(COSTES)

    # Evaluar Ramificación y Poda
    start_time = time.time()
    ramificacion_y_poda(COSTES)
    rp_tiempo = time.time() - start_time

    # Guardar resultados
    resultados.append((N, fb_tiempo, rp_tiempo))

    print(f"Tiempo Fuerza Bruta: {fb_tiempo:.4f} s")
    print(f"Tiempo Ramificación y Poda: {rp_tiempo:.4f} s")

```

=== Evaluando N=3 ===

Fuerza Bruta: Mejor solución: (0, 2, 1) con costo: 58  
Tiempo de ejecución: 0.0001 segundos  
La solución final es: [{'s': (0, 2, 1), 'ci': np.int64(58)}] en 5 iteraciones para dimension: 3  
Tiempo Fuerza Bruta: 0.0001 s  
Tiempo Ramificación y Poda: 0.0002 s

=== Evaluando N=4 ===

Fuerza Bruta: Mejor solución: (0, 3, 1, 2) con costo: 93  
Tiempo de ejecución: 0.0001 segundos  
La solución final es: [{'s': (0, 2, 3, 1), 'ci': np.int64(93)}] en 16 iteraciones para dimension: 4  
Tiempo Fuerza Bruta: 0.0001 s  
Tiempo Ramificación y Poda: 0.0006 s

=== Evaluando N=5 ===

Fuerza Bruta: Mejor solución: (2, 1, 0, 3, 4) con costo: 94  
Tiempo de ejecución: 0.0006 segundos  
La solución final es: [{'s': (0, 1, 3, 2, 4), 'ci': np.int64(96)}] en 27 iteraciones para dimension: 5  
Tiempo Fuerza Bruta: 0.0006 s  
Tiempo Ramificación y Poda: 0.0011 s

=== Evaluando N=6 ===

Fuerza Bruta: Mejor solución: (1, 2, 0, 4, 3, 5) con costo: 103  
Tiempo de ejecución: 0.0038 segundos  
La solución final es: [{'s': (2, 0, 1, 4, 3, 5), 'ci': np.int64(103)}] en 83 iteraciones para dimension: 6  
Tiempo Fuerza Bruta: 0.0038 s  
Tiempo Ramificación y Poda: 0.0078 s

=== Evaluando N=7 ===

Fuerza Bruta: Mejor solución: (6, 3, 0, 1, 2, 5, 4) con costo: 113  
Tiempo de ejecución: 0.0326 segundos  
La solución final es: [{'s': (2, 3, 4, 1, 6, 5, 0), 'ci': np.int64(113)}] en 785 iteraciones para dimension: 7  
Tiempo Fuerza Bruta: 0.0326 s  
Tiempo Ramificación y Poda: 0.1007 s

=== Evaluando N=8 ===

Fuerza Bruta: Mejor solución: (4, 0, 5, 2, 7, 6, 1, 3) con costo: 144  
Tiempo de ejecución: 0.2777 segundos  
La solución final es: [{'s': (1, 6, 7, 5, 0, 2, 3, 4), 'ci': np.int64(145)}] en 2324 iteraciones para dimension: 8  
Tiempo Fuerza Bruta: 0.2777 s  
Tiempo Ramificación y Poda: 0.6387 s

=== Evaluando N=9 ===

Fuerza Bruta: Mejor solución: (6, 5, 3, 0, 2, 7, 1, 8, 4) con costo: 145  
Tiempo de ejecución: 1.2677 segundos  
La solución final es: [{'s': (3, 6, 4, 2, 8, 1, 0, 5, 7), 'ci': np.int64(145)}] en 1112 iteraciones para dimension: 9

Tiempo Fuerza Bruta: 1.2677 s  
 Tiempo Ramificación y Poda: 0.1063 s

=== Evaluando N=10 ===

Fuerza Bruta: Mejor solución: (5, 3, 7, 9, 6, 8, 4, 0, 2, 1) con costo: 168

Tiempo de ejecución: 15.8074 segundos

La solución final es: [{'s': (7, 9, 8, 1, 6, 0, 4, 2, 5, 3), 'ci': np.int64(168)}] en 8020 iteraciones para dimension: 10

Tiempo Fuerza Bruta: 15.8074 s

Tiempo Ramificación y Poda: 5.0241 s

=== Evaluando N=11 ===

Fuerza Bruta: Mejor solución: (8, 6, 2, 3, 10, 7, 4, 9, 5, 1, 0) con costo: 145

Tiempo de ejecución: 195.3227 segundos

La solución final es: [{'s': (10, 9, 2, 3, 6, 8, 1, 5, 0, 7, 4), 'ci': np.int64(145)}] en 15945 iteraciones para dimension: 11

Tiempo Fuerza Bruta: 195.3227 s

Tiempo Ramificación y Poda: 25.9166 s

```
In [17]: resultados2 = []
for N in range(3, 12): # Desde 3x3 hasta 13x13
    print(f"\n=== Evaluando N={N} ===")
    COSTES = generar_matriz_costos(N)

    # Evaluar Ramificación y Poda
    start_time = time.time()
    ramificacion_y_poda(COSTES)
    rp_tiempo = time.time() - start_time

    # Guardar resultados
    resultados2.append((N, rp_tiempo))

    print(f"Tiempo Ramificación y Poda: {rp_tiempo:.4f} s")
```



=== Evaluando N=3 ===

La solución final es: [{'s': (2, 0, 1), 'ci': np.int64(87)}] en 6 iteraciones para dimension: 3

Tiempo Ramificación y Poda: 0.0002 s

=== Evaluando N=4 ===

La solución final es: [{'s': (2, 1, 0, 3), 'ci': np.int64(106)}] en 12 iteraciones para dimension: 4

Tiempo Ramificación y Poda: 0.0003 s

=== Evaluando N=5 ===

La solución final es: [{'s': (1, 0, 2, 3, 4), 'ci': np.int64(84)}] en 12 iteraciones para dimension: 5

Tiempo Ramificación y Poda: 0.0004 s

=== Evaluando N=6 ===

La solución final es: [{'s': (1, 3, 0, 5, 4, 2), 'ci': np.int64(96)}] en 49 iteraciones para dimension: 6

Tiempo Ramificación y Poda: 0.0014 s

=== Evaluando N=7 ===

La solución final es: [{'s': (5, 6, 2, 3, 4, 0, 1), 'ci': np.int64(104)}] en 473 iteraciones para dimension: 7

Tiempo Ramificación y Poda: 0.0340 s

=== Evaluando N=8 ===

La solución final es: [{'s': (3, 7, 6, 5, 2, 4, 1, 0), 'ci': np.int64(113)}] en 829 iteraciones para dimension: 8

Tiempo Ramificación y Poda: 0.0966 s

=== Evaluando N=9 ===

La solución final es: [{'s': (5, 0, 7, 6, 8, 1, 4, 3, 2), 'ci': np.int64(141)}] en 1835 iteraciones para dimension: 9

Tiempo Ramificación y Poda: 0.3596 s

=== Evaluando N=10 ===

La solución final es: [{'s': (2, 1, 6, 5, 0, 8, 4, 3, 9, 7), 'ci': np.int64(178)}] en 5285 iteraciones para dimension: 10

Tiempo Ramificación y Poda: 2.6881 s

=== Evaluando N=11 ===

La solución final es: [{'s': (4, 8, 10, 0, 6, 7, 5, 2, 9, 1, 3), 'ci': np.int64(153)}] en 3440 iteraciones para dimension: 11

Tiempo Ramificación y Poda: 1.9450 s


```
In [18]: # Crear DataFrame con los resultados
df = pd.DataFrame(resultados, columns=['N', 'Fuerza Bruta (s)', 'Ramificación y Poda (s)'])

DataTable(df) # Muestra la tabla interactiva

# Graficar los tiempos de ejecución
plt.figure(figsize=(8, 5))
plt.plot(df['N'], df['Fuerza Bruta (s)'], marker='o', linestyle='-', label='Fuerza Bruta (s)')
plt.plot(df['N'], df['Ramificación y Poda (s)'], marker='s', linestyle='-', label='Ramificación y Poda (s)')

plt.xlabel("Dimensión N")
plt.ylabel("Tiempo de ejecución (s)")
plt.title("Comparación de tiempos de ejecución")
plt.legend()
```

```
plt.grid(True)
plt.show()
```




```
In [19]: # Crear DataFrame con los resultados
df2 = pd.DataFrame(resultados2, columns=['N', 'Ramificación y Poda (s)'])

DataTable(df2) # Muestra la tabla interactiva

# Graficar los tiempos de ejecución
plt.figure(figsize=(8, 5))
plt.plot(df2['N'], df2['Ramificación y Poda (s)'], marker='s', linestyle=

plt.xlabel("Dimensión N")
plt.ylabel("Tiempo de ejecución (s)")
plt.title("Comparación de tiempos de ejecución")
plt.legend()
plt.grid(True)
plt.show()
```



## ¿A partir de qué dimensión el algoritmo por fuerza bruta deja de ser una opción?

El algoritmo de **fuerza bruta** evalúa todas las posibles asignaciones, por lo que su **complejidad factorial**  $O(n!)$  hace que el tiempo de ejecución crezca de manera exponencial. Según nuestras pruebas:

- Para  $n = 3$  a  $n = 6$ , el tiempo de ejecución es manejable.
- Para  $n = 7$ , se observa un incremento notable en el tiempo de cómputo.
- Para  $n = 8$ , la ejecución ya se vuelve muy lenta.
- Para  $n \geq 9$ , el tiempo de ejecución es **demasiado alto** y no se pudo completar en un tiempo razonable.

Por lo tanto, **fuerza bruta deja de ser viable a partir de  $n = 8$**  en este experimento.

## ¿Hay algún valor de la dimensión a partir del cual el algoritmo de ramificación y poda también deja de ser una opción válida?

El algoritmo de **ramificación y poda** mejora la eficiencia mediante la eliminación de ramas no óptimas, reduciendo el espacio de búsqueda en comparación con la fuerza bruta. Sin embargo, su **complejidad aún es exponencial** en el peor caso.

En esta prueba:

- Para  $n = 3$  a  $n = 8$ , el tiempo de ejecución se mantuvo aceptable.

- Para  $n = 9$  y  $n = 10$ , el tiempo de ejecución aumentó, pero el algoritmo aún finalizó en un tiempo razonable.
- Para  $n > 10$ , el tiempo de ejecución comenzó a ser **excesivo**, y no se logró determinar en qué punto exacto deja de ser viable.

Dado que el rendimiento del algoritmo de **ramificación y poda depende del número de podas efectuadas**, en esta ejecución no fue posible determinar con certeza un límite exacto para su utilidad.

## Conclusión

- **Fuerza bruta** deja de ser viable a partir de  $n = 8$ .
- **Ramificación y poda** sigue siendo manejable hasta  $n = 10$ , pero para valores mayores el tiempo de ejecución aumenta considerablemente.
- No se pudo determinar un **punto exacto** donde **ramificación y poda deja de ser viable**, ya que depende de la estructura del problema y de la cantidad de podas realizadas.

Para valores de  $> 10$ , se recomienda explorar **técnicas heurísticas o metaheurísticas** como **búsqueda tabú, algoritmos genéticos o enfoques de optimización aproximada**.

## Descenso del gradiente

```
In [20]: import math                                #Funciones matematicas
import matplotlib.pyplot as plt                    #Generacion de gráficos (otra opcion sea
import numpy as np                                #Tratamiento matriz N-dimensionales y ot
import scipy as sc

import random
```

Vamos a buscar el minimo de la funcion paraboloides :

$$f(x) = x^2 + y^2$$

Obviamente se encuentra en  $(x,y)=(0,0)$  pero probaremos como llegamos a él a través del descenso del gradiente.

```
In [21]: #Definimos la funcion
#Paraboloide
f = lambda X: X[0]**2 + X[1]**2                    #Funcion
df = lambda X: [2*X[0], 2*X[1]]                  #Gradiente


df([1,2])
```

```
Out[21]: [2, 4]
```

```
In [22]: from sympy import symbols
from sympy.plotting import plot
from sympy.plotting import plot3d
x,y = symbols('x y')
```

```
plot3d(x**2 + y**2,
       (x,-5,5),(y,-5,5),
       title='x**2 + y**2',
       size=(10,10))
```

$x^2 + y^2$



Out [22]: <sympy.plotting.backends.matplotlibbackend.matplotlib.MatplotlibBackend at 0x7f2f921332d0>

```
In [23]: #Prepara los datos para dibujar mapa de niveles de Z
         resolution = 100
         rango=5.5

         X=np.linspace(-rango,rango,resolucion)
         Y=np.linspace(-rango,rango,resolucion)
         Z=np.zeros((resolucion,resolucion))
         for ix,x in enumerate(X):
             for iy,y in enumerate(Y):
                 Z[iy,ix] = f([x,y])

         #Pinta el mapa de niveles de Z
         plt.contourf(X,Y,Z,resolucion)
         plt.colorbar()

         #Generamos un punto aleatorio inicial y pintamos de blanco
```

```


P=[random.uniform(-5,5 ),random.uniform(-5,5 ) ]
plt.plot(P[0],P[1],"o",c="white")

#Tasa de aprendizaje. Fija. Sería más efectivo reducirlo a medida que nos
TA=.1

#Iteraciones:50
for _ in range(50):
    grad = df(P)
    #print(P,grad)
    P[0],P[1] = P[0] - TA*grad[0] , P[1] - TA*grad[1]
    plt.plot(P[0],P[1],"o",c="red")

#Dibujamos el punto final y pintamos de verde
plt.plot(P[0],P[1],"o",c="green")
plt.show()
print("Solucion:" , P , f(P))


```



Solucion: [6.166972603145723e-05, -3.123344948412927e-05] 4.778683475472648e-09

**¿Te atreves a optimizar la función?:**

$$f(x) = \sin(1/2 * x^2 - 1/4 * y^2 + 3) * \cos(2 * x + 1 - e^y)$$



## PROCEDIMIENTO ADICIONAL

```
In [35]: # Importa numpy para operaciones numéricas eficientes con arreglos y matr
import numpy as np

# Importa pyplot de matplotlib para crear gráficos estáticos e interactiv
import matplotlib.pyplot as plt

# Importa random para generar números aleatorios y hacer selecciones alea
import random

# Importa math para funciones matemáticas como trigonometría y logaritmos
import math

# Importa funciones simbólicas de sympy para crear variables, derivadas y
from sympy import symbols, diff, sin, cos, exp
```

```
In [36]: # Definir variables simbólicas 'x' e 'y' para usar en expresiones simbóli
x, y = symbols('x y')

# Definir la función simbólica f en términos de 'x' e 'y'.
f_sym = sin((1/2) * x**2 - (1/4) * y**2 + 3) * cos(2*x + 1 - exp(y))

# Calcular las derivadas parciales de la función con respecto a 'x' y 'y'
df_dx = diff(f_sym, x)
df_dy = diff(f_sym, y)

# Convertir la función simbólica a una función numérica utilizando lambda
f = lambda X: math.sin((1/2) * X[0]**2 - (1/4) * X[1]**2 + 3) * math.cos(

# Crear una función lambda para calcular el gradiente numérico (derivadas
df = lambda X: [ float(df_dx.evalf(subs={x: X[0], y: X[1]})),
                  float(df_dy.evalf(subs={x: X[0], y: X[1]})) ]
```

```
In [37]: # Definir la función f que se desea graficar
def f(X, Y):
    return np.sin(0.5 * X**2 - 0.25 * Y**2 + 3) * np.cos(2*X + 1 - np.exp

# Crear los datos para el gráfico 3D
x = np.linspace(-5, 5, 100)
y = np.linspace(-5, 5, 100)
X, Y = np.meshgrid(x, y)
Z = f(X, Y)

# Crear la figura y el eje 3D
fig = plt.figure(figsize=(10, 10))
ax = fig.add_subplot(111, projection='3d')


# Graficar la superficie
ax.plot_surface(X, Y, Z, cmap='viridis')

# Añadir título y etiquetas
ax.set_title('Nueva función')
ax.set_xlabel('X')
ax.set_ylabel('Y')
ax.set_zlabel('f(X, Y)')
```



```
# Mostrar el gráfico
plt.show()
```

Nueva función



```
In [38]: # Definir la función f y su gradiente (como en el código anterior)
def f(X):
    return np.sin(0.5 * X[0]**2 - 0.25 * X[1]**2 + 3) * np.cos(2*X[0] + 1)

def df(X):
    # Derivadas parciales calculadas previamente
    df_dx = np.cos(0.5 * X[0]**2 - 0.25 * X[1]**2 + 3) * np.exp(2*X[0] + 1)
    df_dy = -0.5 * X[1] * np.sin(0.5 * X[0]**2 - 0.25 * X[1]**2 + 3) * np
    return [df_dx, df_dy]

# Preparar datos para el mapa de niveles
resolucion = 100
rango = 5.5

X = np.linspace(-rango, rango, resolucion)
Y = np.linspace(-rango, rango, resolucion)
Z = np.zeros((resolucion, resolucion))

# Rellenar la matriz Z con los valores de la función f
for ix, x_val in enumerate(X):
    for iy, y_val in enumerate(Y):
```



```

        Z[iy, ix] = f([x_val, y_val])

# Dibujar el mapa de niveles (contornos)
plt.contourf(X, Y, Z, levels=50, cmap="viridis")
plt.colorbar()

# Generar un punto inicial aleatorio
P = [random.uniform(-rango, rango), random.uniform(-rango, rango)]
plt.plot(P[0], P[1], "o", color="white") # Pintar el punto inicial en blanco


# Tasa de aprendizaje fija
TA = 0.1

# Iteraciones del descenso del gradiente
for _ in range(50):
    grad = df(P) # Calcular el gradiente
    P[0] -= TA * grad[0] # Actualizar x
    P[1] -= TA * grad[1] # Actualizar y
    plt.plot(P[0], P[1], "o", color="red") # Pintar el camino recorrido

# Pintar el punto final en verde
plt.plot(P[0], P[1], "o", color="green")
plt.show()

# Mostrar la solución encontrada
print("Solución encontrada:", P, "Valor de f(P):", f(P))

```



Solución encontrada: [np.float64(1.6572828646319069), np.float64(2.197138617952343)] Valor de f(P): 0.0006887803033128649